Департамент образования и науки города Москвы
Государственное автономное образовательное учреждение
высшего образования города Москвы
«Московский городской педагогический университет»
Институт цифрового образования
Департамент информатики, управления и технологий

ДИСЦИПЛИНА:

«Инструменты для хранения и обработки больших данных»

дз_01

Тема:

«ETL Компоненты и начало работы с ETL на примере Pentaho Data Integration»

Выполнила: Николаева С.Г., АДЭУ-201

Преподаватель: Босенко Тимур Муртазович

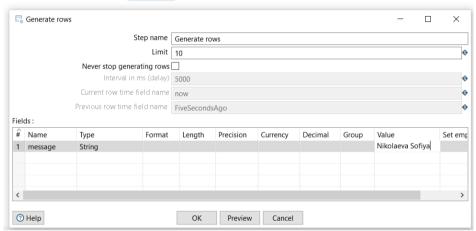
Москва

2023



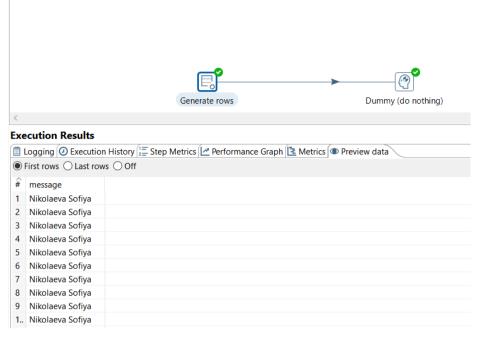
ЗАДАНИЕ1





Rows of step: Generate rows (10 rows)

message
1 Nikolaeva Sofiya
2 Nikolaeva Sofiya
3 Nikolaeva Sofiya
4 Nikolaeva Sofiya
5 Nikolaeva Sofiya
6 Nikolaeva Sofiya
7 Nikolaeva Sofiya
8 Nikolaeva Sofiya
9 Nikolaeva Sofiya
1... Nikolaeva Sofiya
1... Nikolaeva Sofiya



ЗАДАНИЕ2



🗒 Data grid

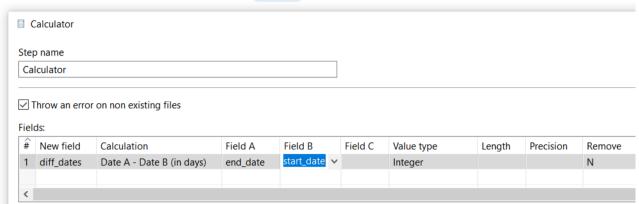
			Step name D
Met	ta Data		
#	project_name	start_date	end_date
1	nikol_1	2000-01-03	2023-04-04
2	nikol_2	2020-01-03	2023-04-04
3	nikol_3	2005-01-03	2023-04-04
4	nikol_4	2009-01-03	2023-04-04
5	nikol_5	2021-01-03	2023-04-04
6			

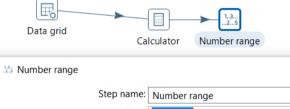
🔀 Examine preview data

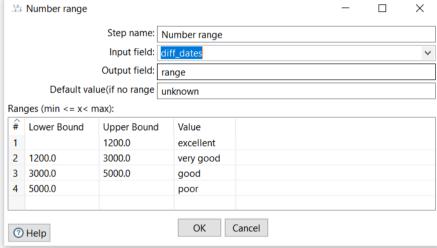
Rows of step: Data grid (6 rows)

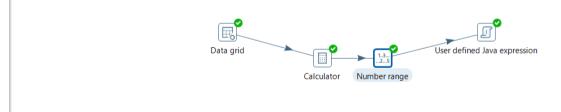
#	project_name	start_date	end_date
1	nikol_1	2000-01-03	2023-04-04
2	nikol_2	2020-01-03	2023-04-04
3	nikol_3	2005-01-03	2023-04-04
4	nikol_4	2009-01-03	2023-04-04
5	nikol_5	2021-01-03	2023-04-04







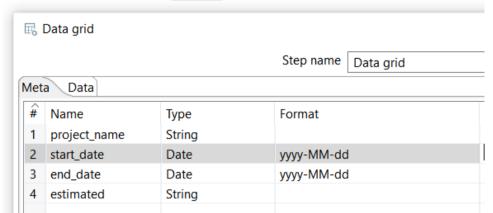




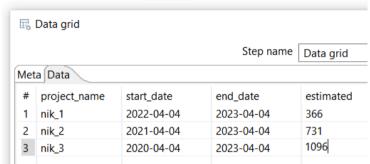
<						
Exe	ecution Result	ts				
	Logging @ Exec	ution History [1=	Step Metrics	Performance C	Graph 🔁 Metric	
● First rows ○ Last rows ○ Off						
#	project_name	start_date	end_date	diff_dates	range	
1	nikol_1	2000-01-03	2023-04-04	8492	poor	
2	nikol_2	2020-01-03	2023-04-04	1187	excellent	
3	nikol_3	2005-01-03	2023-04-04	6665	poor	
4	nikol_4	2009-01-03	2023-04-04	5204	poor	
5	nikol_5	2021-01-03	2023-04-04	821	excellent	
6	nikol_6	2001-04-01	2023-01-01	7945	poor	

ЗАДАНИЕЗ

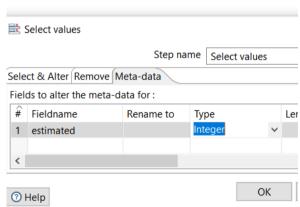


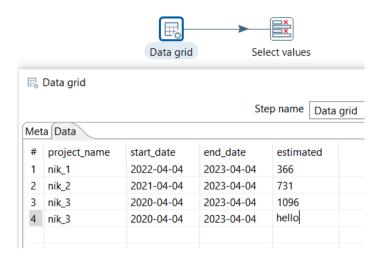


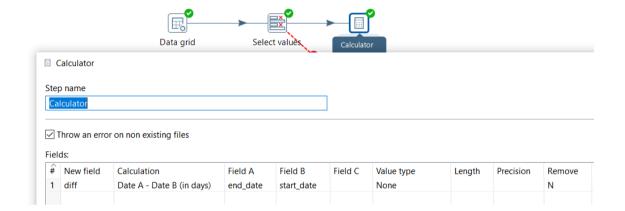


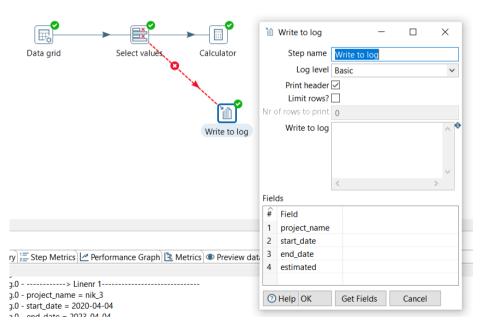












Разделение потока: ошибка – в лог, когда все хорошо сработало -

ПРОХОДИТ

2023/04/04 16:09:37 - Write to log.0 - estimated = hello

Execution Results 🔳 Logging 🕗 Execution History 🏣 Step Metrics 🗠 Performance Graph 🔁 Metrics 👁 Preview data ● First rows ○ Last rows ○ Off project_name start_date end_date estimated diff 2023-04-04 366 365 1 nik 1 2022-04-04 2 nik 2 2021-04-04 2023-04-04 731 730 2023-04-04 2020-04-04 1096 1095

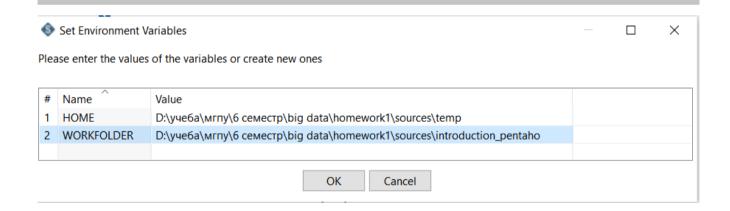
ЗАДАНИЕ4

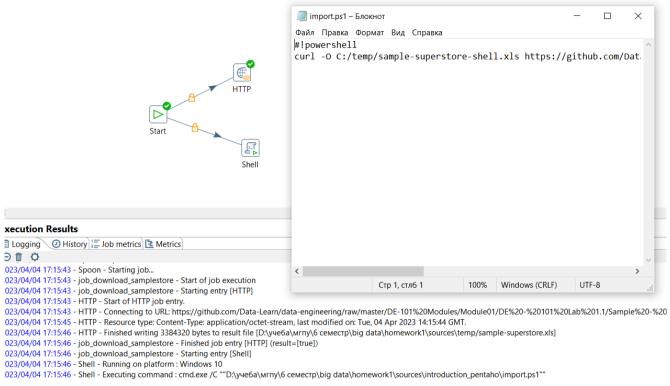
nik 3

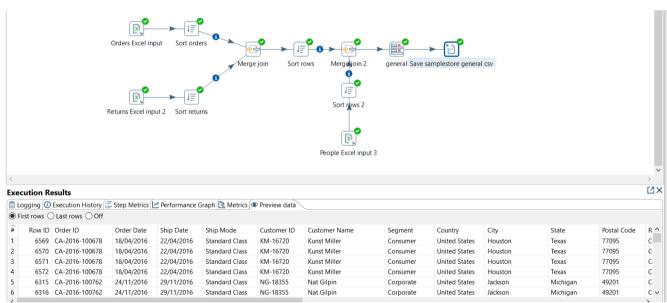
3

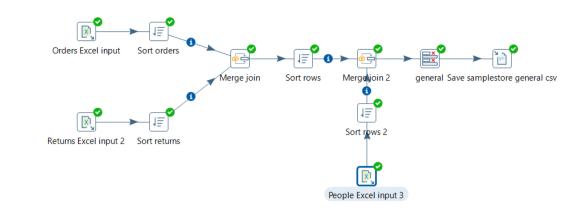
Практика

- Скачаем <u>sample-superstore.xis</u> из 1 модуля. (1 job)
- Объединим данные из 3 таблиц в одну. (1 transformation)
- Разобьем данные на разные форматы (2 transformation)
 - Информацию по продуктам сохраним в JSON формате
 - Информацию о возвратах сохраним в формате XML
 - Информацию о заказах разобьем по регионам:
 - CENTRAL Одним файлом в формате Excel (xls)
 - WEST Несколько файлов разбитых по штатам в сsv
 - SOUTH Один файл формата csv в zip архиве
 - EAST текстовый файл с расширением .dat
- Добавляем "ошибки" для большего реализма :D (3 transformation)
 - WEST разные названия страны (US, United States, USA), лишние символы в поле City
 - EAST- добавляем опечатки в названиях городов (сложно прогнозируемые для ручного исправления)
 - SOUTH добавляем дубли заказов









Execution Results

	□ Logging ② Execution History □ Step Metrics ☑ Performance Graph □ Metrics ● Preview data			
•	● First rows ○ Last rows ○ Off			
#	Person	Region		
1	Anna Andreadi	West		
2	Chuck Magee	East		
3	Kelly Williams	Central		
4	Cassandra Brandow	South		