Департамент образования и науки города Москвы
Государственное автономное образовательное учреждение
высшего образования города Москвы
«Московский городской педагогический университет»
Институт цифрового образования
Департамент информатики, управления и технологий

ДИСЦИПЛИНА:

«Инструменты для хранения и обработки больших данных»

пр_05-02

Тема:

«Introduction to HDFS»

Выполнила: Николаева С.Г., АДЭУ-201

Преподаватель: Босенко Тимур Муртазович

Москва

1. Развернуть виртуальное окружение

2. Вывести с помощью команды help описание основных команды shell-клиента

```
Чт 17:16 ●
                                                                                上 ● Q、
                                                                                      st1@st1-vbox: ~
       File Edit View Search Terminal Help
      50
               Faust
      st1@st1-vbox:~S help
      GNU bash, version 4.4.20(1)-release (x86_64-pc-linux-gnu)
      These shell commands are defined internally. Type `help' to see this list. Type `help name' to find out more about the function `name'.
      Use `info bash' to find out more about the shell in general.
      Use `man -k' or `info' to find out more about commands not in this list.
      A star (*) next to a name means that the command is disabled.
       job_spec [&]
                                                 history [-c] [-d offset] [n] or his>
       (( expression ))
                                                 if COMMANDS; then COMMANDS; [ elif >
jobs [-lnprs] [jobspec ...] or jobs>
       . filename [arguments]
                                                 kill [-s sigspec | -n signum | -sig>
                                                 let arg [arg ...]
       [ arg... ]
                                                 local [option] name[=value] ...
       [[ expression ]]
                                                 logout [n]
       alias [-p] [name[=value] ... ]
       bg [job_spec ...]
                                                 mapfile [-d delim] [-n count] [-0 o>
       bind [-lpsvPSVX] [-m keymap] [-f fil>
                                                popd [-n] [+N | -N]
                                                 printf [-v var] format [arguments]
       break [n]
       builtin [shell-builtin [arg ...]]
                                                 pushd [-n] [+N | -N | dir]
                                                 pwd [-LP]
       caller [expr]
       case WORD in [PATTERN [| PATTERN]...> read [-ers] [-a array] [-d delim] [>
       cd [-L|[-P [-e]] [-@]] [dir]
                                                 readarray [-n count] [-0 origin] [->
       command [-pVv] command [arg ...]
                                                 readonly [-aAf] [name[=value] ...] >
       compgen [-abcdefgjksuv] [-o option] > return [n]
       complete [-abcdefgjksuv] [-pr] [-DE]> select NAME [in WORDS ... ;] do COM>
       compopt [-o|+o option] [-DE] [name .> set [-abefhkmnptuvxBCHP] [-o option>
       continue [n]
                                                 shift [n]
```

3. Просмотреть корневую директорию HDFS

```
st1@st1-vbox:~$ $HADOOP HOME/bin/hadoop fs -ls
Found 2 items
-rw-r--r-- 1 st1 supergroup
                                 187937 2023-04-27 16:28 Faust 1.txt
                                     0 2023-04-27 16:40 Faust 1 Output
drwxr-xr-x - st1 supergroup
stl@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -ls /
Found 2 items
drwxr-xr-x
            - st1 supergroup
                                      0 2023-04-27 16:38 /tmp
drwxr-xr-x
            - st1 supergroup
                                      0 2023-04-27 17:21 /user
st1@st1-vbox:~$ $HADOOP HOME/bin/hadoop fs -ls /user/
Found 3 items
drwxr-xr-x
            - st1 supergroup
                                     0 2023-04-27 22:41 /user/mgpu
drwxr-xr-x - st1 supergroup
                                     0 2023-04-27 17:00 /user/nik
drwxr-xr-x - st1 supergroup
                                     0 2023-04-27 17:01 /user/st1
st1@st1-vbox:~$
```

```
st1@st1-vbox:~/hadoop-3.3.5$ ls
bin lib licenses-binary NOTICE-binary sbin
etc libexec LICENSE.txt NOTICE.txt share
include LICENSE-binary logs README.txt
st1@st1-vbox:~/hadoop-3.3.5$
```

```
st1@st1-vbox:~/hadoop-3.3.5$ cd /bin/
st1@st1-vbox:/bin$ ls
bash
                            networkctl
                                           static-sh
               fuser
brlttv
               fusermount
                           nisdomainname
                                           stty
               getfacl
bunzip2
                            ntfs-3q
                                           su
busybox
               дгер
                            ntfs-3g.probe
                                           sync
bzcat
               gunzip
                            ntfscat
                                           systemctl
                            ntfscluster
bzcmp
                                           systemd
               gzexe
bzdiff
                           ntfscmp
               gzip
                                           systemd-ask-password
               hciconfig
                            ntfsfallocate
                                           systemd-escape
bzegrep
bzexe
               hostname
                            ntfsfix
                                           systemd-hwdb
bzfgrep
                            ntfsinfo
                                           systemd-inhibit
               ίp
               journalctl
                            ntfsls
                                           systemd-machine-id-setup
bzgrep
               kbd_mode
                            ntfsmove
                                           systemd-notify
bzip2
               kill
                                           systemd-sysusers
bzip2recover
                            ntfsrecover
bzless
               kmod
                            ntfssecaudit
                                           systemd-tmpfiles
bzmore
               less
                            ntfstruncate
                                           systemd-tty-ask-password-agent
cat
               lessecho
                            ntfsusermap
               lessfile
                            ntfswipe
chacl
                                           tempfile
```

4. Создать в HDFS в директории /user/mgpu поддиректорию ваше_фио

```
st1@st1-vbox:/bin$ $HADOOP_HOME/bin/hadoop fs -mkdir -p /user/mgpu/nikolaevaSG
```

5. Создать в локальной файловой системе случайный текстовый файл размером 10 Mb с именем, образованным вашими инициалами

```
st1@st1-vbox:~$ base64 /dev/urandom | head -c 100000000 > nsg.txt
```

6. Заархивировать созданный текстовый файл

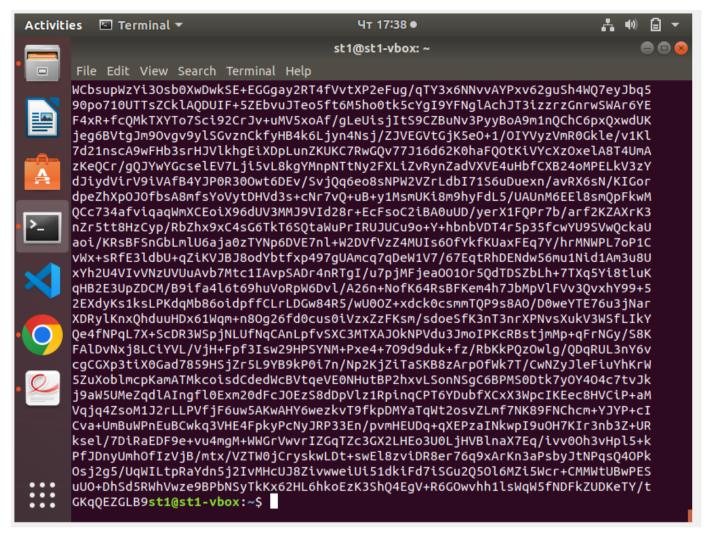
```
st1@st1-vbox:~$ gzip -c nsg.txt > nsg.gz
```

7. Скопировать текстовый файл и архив в директорию /user/mgpu/fio HDFS виртуальной машины

```
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -copyFromLocal nsg.txt /user/mgpu/ni
kolaevaSG
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -copyFromLocal nsg.gz /user/mgpu/nik
olaevaSG
```

8. Просмотреть файл и архив с помощью утилит cat, text в комбинации с каналами и утилитами head, tail -- привести не менее 3 вариантов команд и просмотра файла.

st1@st1-vbox:~\$ \$HADOOP_HOME/bin/hadoop fs -cat /user/mgpu/nikolaevaSG/nsg.txt
part-m-*



GKqQEZGLB9<mark>st1@st1-vbox:</mark>~\$ \$HADOOP_HOME/bin/hadoop fs -cat /user/mgpu/nikolaevaS | head

pke70skyX2z2l/3FEBUSvVZH4S3i7lEY+VZWge5dVI1qyQeHadrFfXvnEW40u3Sjr2JyCpVSdivo 7fkvJK0GA+wWHfnry27uNzui7Je/8GWeTW9R6kgfClrl7o687l8NuHYbqT0c1oCwvSD9IgVtVHfQ jlk+VT0f/x21V3LXAAM183k9IWNuc7eJzyvcfceXCXrXCeB7vEPFen51JTKqI24pNhWVgIsx5w0G IaYiVnZLnS6QzfgmtxV1/vCJSPbdVqUSF9Ran0B3ivLF7oQfzKlFYITS+ugW5Eyr9WBe6urBX85d PFo0Zq5fSEGma8ygax7DeliLjxVQ6mZqyzd1X4eMNPNwo6+QZPgmz3b8GkShW3v0ILJ+BM3QbmdQ /oS4t0cIB9wDA0KPsRAOOZl6oU0oZVl236ZBR5hQ0hVcg/CQZ6UgpYSbeBxbHi3rvx6MmZ1jRUZn Bv2e2AtfVJA3mjomqvDbfPdzSyci7mlE6KgkbAHjfS8JHs/aHAHPTUOsm9h1hqPfZsj6FTjWCU0D 3kh65n0ZXVA1V7VCcHY8wbAvfJPbLgmtwE3GNdZgt/+PEYnoK96ZahBjpklRhzs7+PKsjuXQKNst ukkzEoskkuw5cK8eDzxyJaSxmPBrnbKylXMips1JKbK2qmCefemI5vNE4AF4HzyT0JSh9SyOBZnX JOtg2hATagtXDUx78IyfQRPfPvTiMviabE684U+eutdE+o02fKwej+ZGNBjQo6KLSwH/nNbqFVgz cat: Unable to write to output stream.

st1@st1-vbox:~\$

```
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -cat /user/mgpu/nikolaevaSG/nsg.txt
| tail
cgCGXp3tiX0Gad7859HSjZr5L9YB9kP0i7n/Np2KjZiTaSKB8zArpOfWk7T/CwNZyJleFiuYhKrW
5ZuXoblmcpKamATMkcoisdCdedWcBVtqeVE0NHutBP2hxvLSonNSgC6BPMS0Dtk7yOY404c7tvJk
j9aW5UMeZqdlAIngfl0Exm20dFcJ0EzS8dDpVlz1RpinqCPT6YDubfXCxX3WpcIKEec8HVCiP+aM
Vqjq4ZsoM1J2rLLPVfjF6uw5AKwAHY6wezkvT9fkpDMYaTqWt2osvZLmf7NK89FNChcm+YJYP+cI
Cva+UmBuWPnEuBCwkq3VHE4FpkyPcNyJRP33En/pvmHEUDq+qXEPzaINkwpI9u0H7KIr3nb3Z+UR
ksel/7DiRaEDF9e+vu4mgM+WWGrVwvrIZGqTZc3GX2LHEo3U0LjHVBlnaX7Eq/ivv00h3vHpl5+k
PfJDnyUmh0fIzVjB/mtx/VZTW0jCryskwLDt+swEl8zviDR8er76q9xArKn3aPsbyJtNPqsQ40Pk
Osj2g5/UqWILtpRaYdn5j2IvMHcUJ8ZivwweiUi51dkiFd7iSGu2Q50l6MZi5Wcr+CMMWtUBwPES
uU0+DhSd5RWhVwze9BPbNSyTkKx62HL6hkoEzK3ShQ4EgV+R6GOwvhh1lsWqW5fNDFkZUDKeTY/t
GKqQEZGLB9st1@st1-vbox:~$
```

```
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -text /user/mgpu/nikolaevaSG/nsg.txt
| head
pke70skyX2z2l/3FEBUSvVZH4S3i7lEY+VZWge5dVI1qyQeHadrFfXvnEW40u3Sjr2JyCpVSdivo
7fkvJK0GA+wWHfnry27uNzui7Je/8GWeTW9R6kgfClrl7o687l8NuHYbqTOc1oCwvSD9IgVtVHfQ
jlk+VT0f/x21V3LXAAM183k9IWNuc7eJzyvcfceXCXrXCeB7vEPFen51JTKqI24pNhWVgIsx5w0G
IaYiVnZLnS6QzfgmtxV1/vCJSPbdVqUSF9Ran0B3ivLF7oQfzKlFYITS+ugW5Eyr9WBe6urBX85d
PFo0Zq5fSEGma8ygax7DeliLjxVQ6mZqyzd1X4eMNPNwo6+QZPgmz3b8GkShW3v0ILJ+BM3QbmdQ
/oS4t0cIB9wDA0KPsRA0OZl6oU0oZVl236ZBR5hQ0hVcg/CQZ6UgpYSbeBxbHi3rvx6MmZ1jRUZn
Bv2e2AtfVJA3mjomqvDbfPdzSyci7mlE6KgkbAHjfS8JHs/aHAHPTUOsm9h1hqPfZsj6FTjWCU0D
3kh65n0ZXVA1V7VCcHY8wbAvfJPbLgmtwE3GNdZgt/+PEYnoK96ZahBjpklRhzs7+PKsjuXQKNst
ukkzEoskkuw5cK8eDzxyJaSxmPBrnbKylXMips1JKbK2qmCefemI5vNE4AF4HzyT0JSh9SyOBZnX
JOtg2hATagtXDUx78IyfQRPfPvTiMviabE684U+eutdE+o02fKwej+ZGNBjQo6KLSwH/nNbqFVgz
text: Unable to write to output stream.
st1@st1-vbox:~$
```

```
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -text /user/mgpu/nikolaevaSG/nsg.txt
| tail
cgCGXp3tiX0Gad7859HSjZr5L9YB9kP0i7n/Np2KjZiTaSKB8zArpOfWk7T/CwNZyJleFiuYhKrW
5ZuXoblmcpKamATMkcoisdCdedWcBVtqeVE0NHutBP2hxvLSonNSgC6BPMS0Dtk7yOY404c7tvJk
j9aW5UMeZqdlAIngfl0Exm20dFcJ0EzS8dDpVlz1RpinqCPT6YDubfXCxX3WpcIKEec8HVCiP+aM
Vqjq4ZsoM1J2rLLPVfjF6uw5AKwAHY6wezkvT9fkpDMYaTqWt2osvZLmf7NK89FNChcm+YJYP+cI
Cva+UmBuWPnEuBCwkq3VHE4FpkyPcNyJRP33En/pvmHEUDq+qXEPzaINkwpI9u0H7KIr3nb3Z+UR
ksel/7DiRaEDF9e+vu4mgM+WWGrVwvrIZGqTZc3GX2LHEo3U0LjHVBlnaX7Eq/ivv00h3vHpl5+k
PfJDnyUmh0fIzVjB/mtx/VZTW0jCryskwLDt+swEl8zviDR8er76q9xArKn3aPsbyJtNPqsQ40Pk
Osj2g5/UqWILtpRaYdn5j2IvMHcUJ8ZivwweiUi51dkiFd7iSGu2Q50l6MZi5Wcr+CMMWtUBwPES
uUO+DhSd5RWhVwze9BPbNSyTkKx62HL6hkoEzK3ShQ4EgV+R6GOwvhh1lsWqW5fNDFkZUDKeTY/t
GKqQEZGLB9st1@st1-vbox:~$
```

9. Создать копию файла file.txt вида date_file.txt, где в начале имени файла-копии указана текущая дата. Вывести листинг

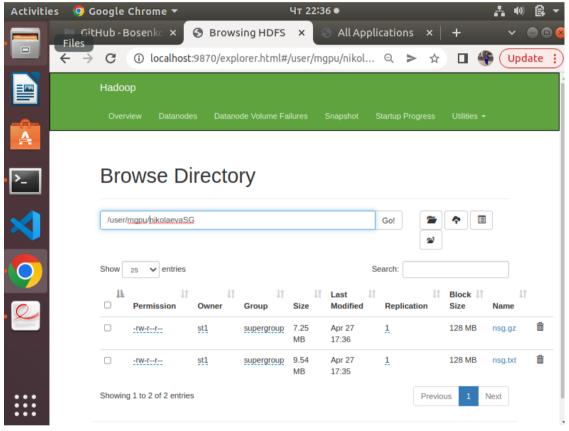
```
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -copyToLocal /user/mgpu/nikolaevaSG
/home/st1/Documents/27-04-2023-nsg.txt

st1@st1-vbox:~$ cd /home/st1/Documents/
st1@st1-vbox:~/Documents$ ls
27-04-2023-nsg.txt
st1@st1-vbox:~/Documents$
```

10. Вывести статистику по директории /user/mgpu/fio виртуальной машины

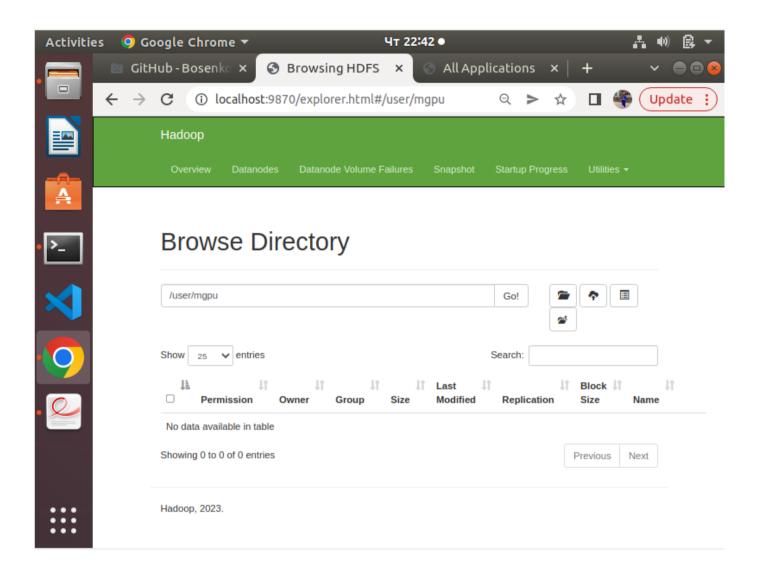
```
st1@st1-vbox:~$ $HADOOP HOME/bin/hadoop fs -dus /user/mgpu/nikolaevaSG
dus: DEPRECATED: Please use 'du -s' instead.
          17599480
                    /user/mgpu/nikolaevaSG
st1@st1-vbox:~$ $HADOOP HOME/bin/hadoop fs -du -s /user/mgpu/nikolaevaSG
                    /user/mapu/nikolaevaSG
17599480
          17599480
st1@st1-vbox:~$ $HADOOP HOME/bin/hadoop fs -du /user/mgpu/nikolaevaSG
                    /user/mgpu/nikolaevaSG/nsg.gz
7599480
          7599480
                    /user/mgpu/nikolaevaSG/nsg.txt
10000000
          10000000
st1@st1-vbox:~S
```

11. Удалить поддиректорию /fio со всем содержимым

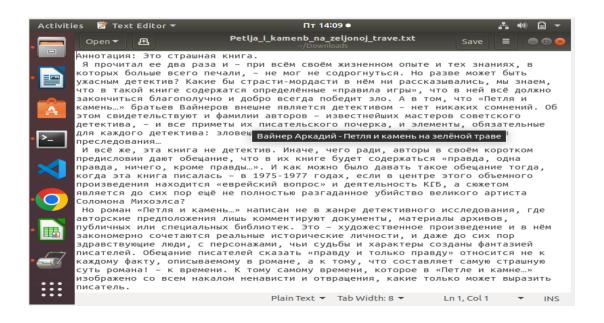


st1@st1-vbox:~\$ \$HADOOP_HOME/bin/hadoop dfs -rm -r /user/mgpu/nikolaevaSG
WARNING: Use of this script to execute dfs is deprecated.
WARNING: Attempting to execute replacement "hdfs dfs" instead.

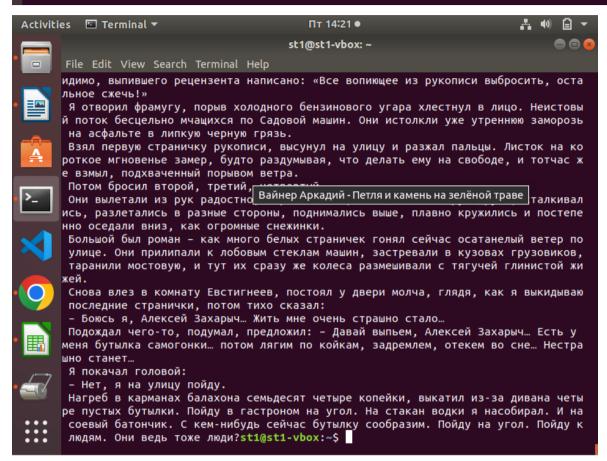
Deleted /user/mgpu/nikolaevaSG
st1@st1-vbox:~\$



Часть 2. Работа с русскоязычным файлом в формате txt

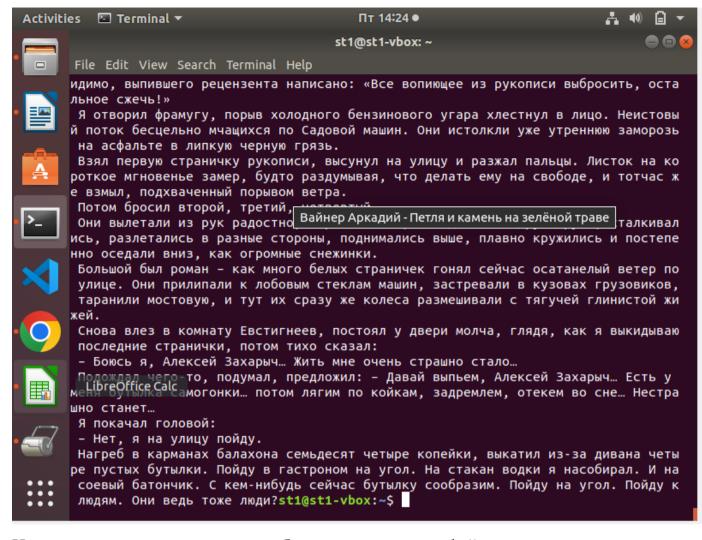


```
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -mkdir -p /user/nikRus/
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -copyFromLocal /home/st1/Downloads/P
etlja_i_kamenb_na_zeljonoj_trave.txt /user/nikRus/
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -cat /user/nikRus/Petlja_i_kamenb_na
_zeljonoj_trave.txt
```



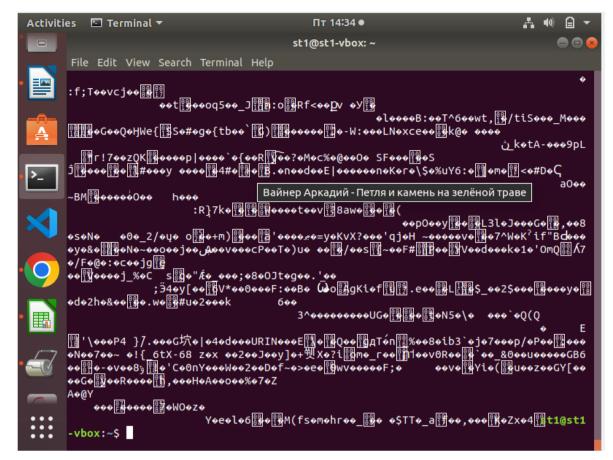
Основное различие между -cat и -text заключается в том, что text определяет кодировку файла и по возможности декодирует его в обычный текст, в то время как cat этого не делает.

```
людям. Они ведь
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -text /user/nikRus/Petlja_i_kamenb_n
a_zeljonoj_trave.txt
```

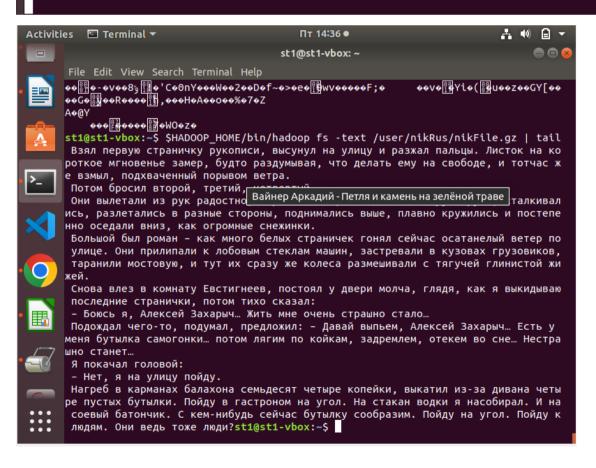


Но разницы пока не видно, попробую заархивировать файл и сделать то же самое.

```
st1@st1-vbox:~/Downloads$ gzip -c Petlja_i_kamenb_na_zeljonoj_trave.txt > nikFi
le.gz
st1@st1-vbox:~/Downloads$ ls
                                mysql-connector-j_8.0.32-1ubuntu18.04_all.deb
nikFile.gz
archive.zip
commons-lang-2.6-bin.tar.gz
  ommons-lang-2.6-src.tar.gz
                                part-r-00000
dpkg.log
                                part-r-00000 (1)'
                                Petlja i kamenb na zeljonoj trave.txt
Exercise_1.pdf
                                sqoop-1.4.7.bin__hadoop-2.6.0.tar.gz
 hadoop-3.3.5.tar.gz
                                work
st1@st1-vbox:~/Downloads$
st1@st1-vbox:~$ $HADOOP HOME/bin/hadoop fs -copyFromLocal /home/st1/Downloads/n
ikFile.gz /user/nikRus/
st1@st1-vbox:~$
```



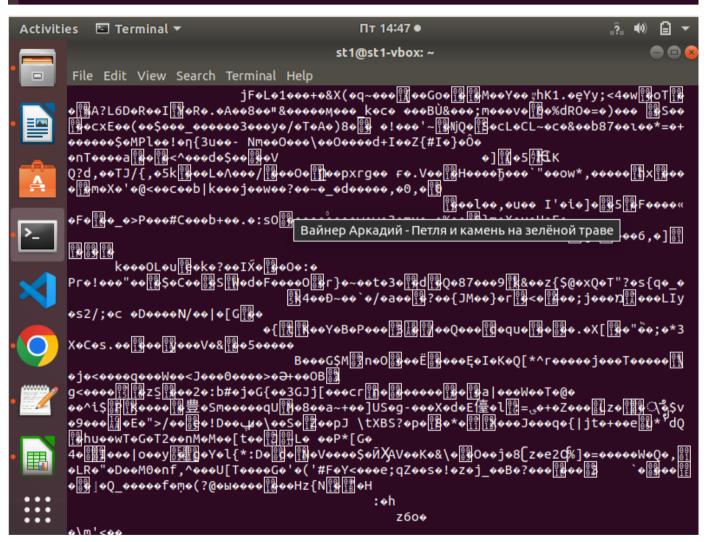
st1@st1-vbox:~\$ \$HADOOP_HOME/bin/hadoop fs -text /user/nikRus/nikFile.gz | tail



ВЫВОД: при работе со сжатым файлом саt не учитывает кодировку файла, что приводит к появлению некорректного отображения файла. В свою очередь команда text учитывает кодировку.

Теперь проверим работу со сжатым файлом с рандомными символами из первой части работы.

```
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -mkdir -p /user/mgpu/Nikolaeva
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -copyFromLocal nsg.gz /user/mgpu/Nik
olaeva
st1@st1-vbox:~$ $HADOOP_HOME/bin/hadoop fs -cat /user/mgpu/Nikolaeva/nsg.gz
```



st1@st1-vbox:~\$ \$HADOOP_HOME/bin/hadoop fs -text /user/mgpu/Nikolaeva/nsg.gz |
head

pke70skyX2z2l/3FEBUSvVZH4S3i7lEY+VZWge5dVI1qyQeHadrFfXvnEW40u3Sjr2JyCpVSdivo 7fkvJK0GA+wWHfnry27uNzui7Je/8GWeTW9R6kgfClrl7o687l8NuHYbqTOc1oCwvSD9IgVtVHfQ jlk+VT0f/x21V3LXAAM183k9IWNuc7eJzyvcfceXCXrXCeB7vEPFen51JTKqI24pNhWVgIsx5w0G IaYiVnZLnS6QzfgmtxV1/vCJSPbdVqUSF9Ran0B3ivLF7oQfzKlFYITS+ugW5Eyr9WBe6urBX85d PFo0Zq5fSEGma8ygax7DeliLjxVQ6mZqyzd1X4eMNPNwo6+QZPgmz3b8GkShW3v0ILJ+BM3QbmdQ /oS4t0cIB9wDA0KPsRAOOZl6oU0oZVl236ZBR5hQ0hVcg/CQZ6UgpYSbeBxbHi3rvx6MmZ1jRUZn Bv2e2AtfVJA3mjomqvDbfPdzSyci7mlE6KgkbAHjfS8JHs/aHAHPTUOsm9h1hqPfZsj6FTjWCU0D 3kh65n0ZXVA1V7VCcHY8wbAvfJPbLgmtwE3GNdZgt/+PEYnoK96ZahBjpklRhzs7+PKsjuXQKNst ukkzEoskkuw5cK8eDzxyJaSxmPBrnbKylXMips1JKbK2qmCefemI5vNE4AF4HzyT0JSh9SyOBZnX JOtg2hATagtXDUx78IyfQRPfPvTiMviabE684U+eutdE+oO2fKwej+ZGNBjQo6KLSwH/nNbqFVgz text: Unable to write to output stream.

st1@st1-vbox:~\$